

INT104 Artificial Intelligence

人工智能

内容基于LearningMall的PPT。仅供学习和交流使用。任何机构或个人不得将其用于商业用途或未经授权的传播。如需引用或分享，请注明出处并保留此声明。



GITHUB

REPOSITORY



VISIT NOTES AUTHOR'S PAGE

CLICK ME

■ [Week 1 + Week 2]





第一周是介绍，第二周讲了一些python，可以找到同目录下的 `Python.pdf` 查看。

[0] 课程信息

Teacher	Mail	Office Hour
Dr. Shengchen LI (Module Leader)	Shengchen.Li@xjtlu.edu.cn	4-5 pm Thursdays 10-11 am Fridays
Prof. Dechang XU	Dechang.Xu@xjtlu.edu.cn	9 am Mondays

[1] 简单介绍

关于机器学习...




人工智能系统面临的挑战

- Insufficient data 数据不足
- Nonrepresentative Training Data 非代表性训练数据
- Poor data quality 数据质量差
- Irrelevant Features 无关功能
- Overfitting 过拟合

- Underfitting 欠拟合
- Data Mismatch (Data Domain) 数据不匹配 (数据域)

[2] 关于python



Python 是解释型语言，不同于Java和C这些编译型语言。

Python需要自己学！本课程不会一步步地教授！课程提供了一些网址：

1. [Learn Python - Free Interactive Python Tutorial](#)
2. [NumPy](#)
3. [SciPy](#)
4. [scikit-learn: machine learning in Python — scikit-learn 1.6.1 documentation](#)

在Week1的Lecture中包含了总共6小时的 python 教程（BigBlueButton），请查看同目录下的 `python.pdf`。


Python可以使命令行、IDE、DeepNote和Jupyter（基于浏览器的IDE）来运行...

■ [Week 3]

数据收集与数据分布 Data Collection & Data Distribution

这节课主要介绍了一些数学概念

[0] 数据训练过程是怎么样的呢？



一些常见的数据结构

	结构化数据 (Structured data)	非结构化数据 (Unstructured data)	半结构化数据 (Semi-structured data)
格式 (Formats)	表格、行、列	文本、图像、音频、视频	XML、JSON、CSV
数据模型 (Data model)	关系型 (Relational)	无	层次型/图型 (Hierarchical/Graph)
常见存储方式 (Common storages)	关系型数据库 (Relational databases)、传统数据仓库 (traditional data warehouses)	文件系统 (File systems)、数据湖 (data lakes)、云数据仓库 (cloud data warehouses)	NoSQL数据库 (NoSQL databases)
数据性质 (Data nature)	定义明确，模式固定 (Well - defined, fixed schema)	不可预测，无模式 (Unpredictable, no schema)	模式松散 (Loose schema)
分析方法 (Analysis methods)	SQL查询、数据挖掘 (SQL queries, data mining)	自然语言处理 (NLP)、图像识别、视频分析、文本分析、音频分析等	查询语言、数据挖掘 (Query languages, data mining)
工具和技术 (Tools and technologies)	微软SQL Server (Microsoft SQL Server)、Oracle、MySQL	亚马逊S3 (Amazon S3)、Hadoop、Spark	MongoDB、Cassandra、Couchbase

	数据仓库 (Data warehouses)	数据湖 (Data lakes)	数据集市 (Data marts)
用途	满足整个组织的数据分析和报告需求	满足不同类型和难度的报告需求、进行预测分析	满足特定运营部门或主题的报告需求
存储的数据 (通常)	大量结构化数据；已处理	大量结构化和非结构化数据；原始	有限的结构化数据；已处理
数据源	一系列外部和内部数据源，涵盖不同业务领域	任何外部或内部数据源	与一个业务领域相关的少数数据源
大小	大于100GB	大于100GB	小于100GB
创建难度	难以设置	难以设置	容易设置

方法	成本效益	速度	定制化程度	隐私级别
众包	中等	高	高	中等
托管数据收集	低	中等	高	高
自动化数据收集	高	高	中等	低
自动化数据生成（合成数据）	高	高	高	中等
授权数据集	中等	高	低	低
机构合作	中等	中等	高	中等

[1] 数据类型

数值型

Numeric

以数字刻度表示的数据。

- **连续型 (Continuous)**：可以在一个区间内取任意值的数据。
(同义词：区间型 (interval)、浮点型 (float)、数值型 (numeric))
- **离散型 (Discrete)**：只能取整数值的数据，比如计数。
(同义词：整型 (integer)、计数型 (count))

分类型

Categorical

只能取一组特定值，这些值代表一系列可能类别的数据。

- (同义词：枚举型 (enums)、列举型 (enumerated)、因子型 (factors)、标称型 (nominal))
- **二元型 (Binary)**：分类型数据的一种特殊情况，只有两个类别的值，例如 0/1、真 / 假。
(同义词：二项型 (dichotomous)、逻辑型 (logical)、指示型 (indicator)、布尔型 (boolean))
- **有序型 (Ordinal)**：具有明确顺序的分类型数据。
(同义词：有序因子型 (ordered factor))

[2] 矩形数据

(Rectangular Data)

数据框 Data frame

矩形数据（类似电子表格）是统计和机器学习模型的基本数据结构。

特征 Feature

表格中的一列通常被称为一个特征。

同义词：属性（attribute）、输入（input）、预测变量（predictor）、变量（variable）

结果 Outcome

许多数据科学项目都涉及预测一个结果，通常是“是/否”类型的结果。在实验或研究中，特征有时被用来预测结果。

同义词：因变量（dependent variable）、响应（response）、目标（target）、输出（output）

记录 Records

表格中的一行通常被称为一条记录。

同义词：案例（case）、示例（example）、实例（instance）、观测值（observation）、模式（pattern）、样本（sample）

[3] 位置估计量

Estimates of Location

均值 Mean

所有数值的总和除以数值的个数。

同义词：平均数（average）

加权均值 Weighted mean

所有数值乘以相应权重后的总和，再除以权重的总和。

同义词：加权平均数（weighted average）

中位数 Median

将数据分成数量相等的两部分，该数值恰好在中间位置。

同义词：第50百分位数（50th percentile）

百分位数 Percentile

使得数据中 $P\%$ 的数据小于该数值。

同义词：分位数（quantile）

加权中位数 Weighted median

在已排序的数据中，使得权重总和的一半分别位于该数值之上和之下的数值。

假设我们有一组数据及其对应的权重：

数据值 x	权重 w
3	2
5	3
7	1
9	4

首先，将数据按照数据值从小到大排序：

数据值 x	权重 w	累计权重 C_w
3	2	2
5	3	2+3=5
7	1	5+1=6
9	4	6+4=10

权重总和为 $2 + 3 + 1 + 4 = 10$ ，一半的权重总和是 $10/2 = 5$ 。

从累计权重可以看出，当取到数据值 $x = 5$ 时，其累计权重为 5，满足“**权重总和 ($2 + 3 + 1 + 4 = 10$) 的一半分别位于该数值之上和之下**”（小于 5 的数据对应的权重累计为 2，大于5 的数据对应的权重累计为 $1+4=5$ ）。所以这组数据的加权中位数就是5。

截尾均值 Trimmed mean

剔除一定数量的极端值后，所有数值的平均值。

同义词：切尾均值 (truncated mean)

稳健的 Robust

对极端值不敏感。

同义词：抗干扰的 (resistant)

离群值 Outlier

与大多数数据值差异很大的数据值。

同义词：极端值 (extreme value)

[4] 变异性度量

Variability Metrics

偏差 Deviations

观测值与位置估计量之间的差值。

同义词：误差 (errors)、残差 (residuals)

方差 Variance

各数据值与均值之差的平方和，除以 $n - 1$ ，其中 n 是数据值的数量。

同义词：均方误差 mean-squared-error

标准差 Standard deviation

方差的平方根。

平均绝对偏差 Mean absolute deviation

各数据值与均值之差的绝对值的平均值。

同义词： $L1$ 范数 ($l1$ -norm)、曼哈顿范数 (Manhattan norm)

中位数绝对偏差 Median absolute deviation from the median

各数据值与中位数之差的绝对值的中位数。

极差 Range

数据集中最大值与最小值之间的差值。

顺序统计量 Order statistics

基于将数据值从小到大排序后得到的度量。

同义词：秩 (ranks)

百分位数 Percentile

这样一个数值，使得数据中 $P\%$ 的数值小于等于该值， $(100 - P)\%$ 的数值大于等于该值。

同义词：分位数 (quantile)

四分位距 (Interquartile range)

第75百分位数与第25百分位数之间的差值。

同义词：IQR (Interquartile Range)

自由度，以及分母该用 n 还是 $n - 1$?

在统计学书籍中，总会讨论为什么方差公式的分母是 $n - 1$ ，而不是 n ，这就引出了自由度的概念。不过这种区别其实并不重要，因为通常 n 足够大，除以 n 还是 $n - 1$ 不会产生太大差异。但如果你感兴趣，下面来解释一下。这基于你想通过样本对总体进行估计的前提。

为什么使用 $n - 1$ 而不是 n ?

1. 无偏估计:

如果在方差公式中使用直观的分母 n ，你会低估总体方差和标准差的真实值，这被称为有偏估计。然而，如果用 $n - 1$ 代替 n 作为分母，方差就会成为无偏估计。

2. 自由度的概念:

要完整解释为什么使用 n 会导致有偏估计，就涉及到自由度的概念，自由度考虑了在计算估计值时的约束条件数量。在这种情况下，有 $n - 1$ 个自由度，因为存在一个约束条件：标准差的计算依赖于样本均值。

总结

对于大多数问题，数据科学家无需担心自由度的问题。当样本量 n 较大时，除以 n 还是 $n - 1$ 的差异可以忽略不计。

[5] 探索数据分布

箱线图 Boxplot

由图基 (Tukey) 提出的一种能快速可视化数据分布的图形。

同义词：盒须图 (box and whiskers plot)

频率表 Frequency table

对落入一组区间（组距）内的数值型数据值的计数统计。

直方图 Histogram

一种以组距为横轴，计数（或比例）为纵轴的频率表图形。虽然在视觉上相似，但条形图不应与直方图混淆。

密度图 Density plot

直方图的平滑版本，通常基于核密度估计。

[6] 探索分类数据

众数 Mode

数据集中出现频率最高的类别或数值。

期望值 Expected value

当各个类别可与一个数值相关联时，期望值是基于某一类别出现的概率得出的平均值。

条形图 Bar charts

将每个类别的频率或比例以条形的形式绘制出来的图表。

饼图 Pie charts

将每个类别的频率或比例以扇形的形式绘制在一个圆形中呈现的图表。

[7] 相关性

相关系数 Correlation coefficient

一种用于衡量数值型变量之间相互关联程度的度量（取值范围从 -1 到 +1）。

相关矩阵 Correlation matrix

一种表格，其中行和列均表示变量，单元格中的值是变量之间的相关系数。

$$r = \frac{n(\sum xy) - (\sum x)(\sum y)}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}}$$



Karl Pearson

散点图 Scatterplot

一种图形，其中 x 轴表示一个变量的值，y 轴表示另一个变量的值。

探索两个或多个变量

列联表 Contingency table

对两个或多个分类变量之间的计数统计列表。

六边形分箱图 Hexagonal binning

一种展示两个数值型变量的图形，记录数据被划分到六边形区域中。

等高线图 Contour plot

一种像地形图一样，展示两个数值型变量密度的图形。


小提琴图 Violin plot

与箱线图类似，但会展示密度估计。

[8] 总体和样本

左边是总体，包含了所有的黑色小点，意味着总体是集合...包含了研究对象这些小个体

右边代表样本，是从总体中抽取的一部分黑色小点，说明样本是子集，从总体中选出的。箭头表示从总体中抽取样本的过程。



[9] 随机抽样

样本 Sample

从更大的数据集中选取的一个子集。

总体 Population

更大的数据集，或对数据集的一种概念性表述。

N (n)

总体（样本）的规模大小。

随机抽样 Random sampling

随机地从总体中抽取元素组成样本。

分层抽样 Stratified sampling

将总体划分为不同的层，然后从每一层中随机抽样。

层 (Stratum, 复数strata)

总体中具有共同特征的同类子群体。

简单随机样本 Simple random sample

在不对总体进行分层的情况下，通过随机抽样得到的样本。

偏差 Bias

系统性误差。

样本偏差 Sample bias

无法准确代表总体特征的样本。

选择偏差 Select Bias

1. 选择偏差 Selection bias

因观测对象选取方式而产生的偏差。

2. 数据窥探 Data snooping

对数据进行大量搜寻，以寻找有趣的信息。

3. 大规模搜索效应 Vast search effect

由于重复进行数据建模，或使用大量预测变量对数据进行建模而导致的偏差或不可重复性。

[10] 抽样分布

Sampling Distribution

样本统计量 Sample statistic

从较大总体中抽取的样本数据所计算得出的一种度量指标。

数据分布 Data distribution

数据集中单个数值的频率分布。

抽样分布 Sampling distribution

在多个样本或重抽样中，样本统计量的频率分布。

中心极限定理 Central limit theorem

随着样本量增加，抽样分布趋于正态分布的一种趋势。

标准误差 Standard error

多个样本中样本统计量的变异性（标准差）（不要与标准差混淆，标准差本身指的是单个数据值的变异性）。

[11] 自助法

Bootstrap

自助样本 Bootstrap sample

从观测数据集中有放回抽样得到的样本。

重抽样 Resampling

从观测数据中反复抽取样本的过程，包括自助法和排列（打乱）法。

[12] 置信区间

Confidence Intervals

置信水平 Confidence level

以相同方式从同一总体中构造的置信区间中，预期包含感兴趣统计量的比例。

区间端点 Interval endpoints

置信区间的上限和下限。


[13] 正态分布

Normal Distribution

正态曲线 Normal Curve

μ 代表均值，是正态分布的中心位置；


σ 代表标准差，衡量数据的离散程度。



正态曲线 (Normal curve)


左侧图像：是一个二维正态分布的概率密度函数的立体图，体现了二维正态分布在平面上不同点的概率密度值。

在二维正态分布中，数据点的概率密度呈现出类似山峰的形状，中心部分概率密度最高，离中心越远，概率密度越低
注意是二维的




右侧图像：展示了二维正态分布的数据点分布情况，绿色椭圆区域内分布着大量的数据点。两侧红色和蓝色曲线分别是变量 X 和 Y 的边缘分布，体现了每个变量单独的概率分布情况。

* 边缘分布是指在多维概率分布中，不考虑其他变量，仅关注某一个变量的概率分布情况。



$$(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$$

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp\left(\frac{-1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right)$$



它是无监督学习的一种重要方法，目的是将数据集中的样本按照相似性划分为不同的组（即簇），使得同一簇内的样本相似度较高，而不同簇间的样本相似度较低。比如在高斯混合模型（GMM）和 DBSCAN 算法中，都是通过特定的方式对数据进行处理，从而得到不同的 cluster，帮助发现数据中的内在结构和模式。

误差 Error

数据点与预测值或平均值之间的差值。

标准化 Standardize

减去均值，然后除以标准差。

z分数 z-score

对单个数据点进行标准化后的结果。

标准正态分布 Standard normal


均值为0、标准差为1的正态分布。

QQ图 QQ-Plot

一种用于可视化样本分布与指定分布（如正态分布）接近程度的图形。

[14] 长尾分布

Long-Tailed Distributions



**奈飞 (Netflix, 股票代码 NFLX) 收益率的 QQ-Plot
这个属于长尾分布**

尾部 Tail

频率分布中细长的部分，在该部分相对极端的值出现的频率较低。

偏度 Skew

指分布的一侧尾部比另一侧更长的情况。

[15] 学生 t 分布


Student's t distribution

n

样本量

自由度

一个能让 t 分布根据不同样本量、统计量和组数进行调整的参数。



戈塞特 (Gosset) 的重抽样实验

实验结果及拟合的t曲线 (来自他1908年发表于《生物统计学》期刊的论文)

[16] 二项分布

Binomial Distribution

试验 Trial

具有离散结果的一个事件 (例如, 抛硬币)。

成功 Success

试验中所关注的结果。

同义词: “1” (相对于“0”而言)

二项的 Binomial

具有两种结果的。

同义词: 是/否, 0/1, 二元的

二项试验 Binomial trial

有两种结果的试验。

同义词: 伯努利试验

二项分布 Binomial distribution

在 X 次试验中成功次数的分布。

同义词: 伯努利分布

[17] 泊松分布及相关分布

Poisson and Related Distributions

兰布达 Lambda

事件发生的速率 (每单位时间或空间)。

泊松分布 Poisson distribution

在抽样的单位时间或空间内事件发生数量的频率分布。

指数分布 Exponential distribution

从一个事件到下一个事件的时间或距离的频率分布。

威布尔分布 Weibull distribution

指数分布的一种广义形式，其中事件发生的速率允许随时间变化。

■ [Week 4]

数据特征与主成分分析 Data Features & Principal Component Analysis

这节课讲了PCA的原理（很复杂），以及如何用Python实现PCA（也很复杂）

一个示例是 [鸢尾花数据集上的主成分分析 \(PCA\)](#)，用到的数据集[在这里](#)。




•Iris Setosa



•Iris Versicolor



•Iris Virginica



数据特征

特征 Feature

表格中的一列 (row, tuple) 通常被称为一个特征。

同义词：属性 (Attribute)、输入 (Input)、预测变量 (Predictor)、变量 (Variable)

机器学习中的主成分分析

Principal Component Analysis in Machine Learning

主成分

预测变量的线性组合。

载荷 Loadings

将预测变量转换为主成分的权重。


同义词：权重

碎石图

一种展示主成分方差的图，以解释方差或解释方差的比例的形式，呈现各主成分的相对重要性。

主成分分析（PCA）的主要目标是在尽可能保留信息的前提下，**减少数据集中的变量数量**。

机器学习中的主成分分析主要用于降维和重要特征选择。将相关特征转化为独立特征。



Harold Hotelling

为了进行全面、系统的分析和研究，需要考虑众多指标，这些指标能够从不同方面反映研究对象的特征，但指标过多会增加分析的复杂性。

能否将原始变量精简为几个具有代表性的新变量，来代表原来的指标呢？

示例引入

约翰·理查德·尼古拉斯·斯通 是一位具有开创性的经济学家，他开发了一种**系统的复式记账法**用于国民收入核算。他在 1984 年被授予诺贝尔经济学奖。

他使用了美国 1929 年至 1938 年的数据，**得出了 17 个反映国民收入和支出的变量**，如雇主补贴、消费和生产资料、公共净支出、存货净增加、股息、利息以及对外贸易差额。

经过主成分分析（PCA）后，原本的 17 个变量被降维为 3 个新的变量，降维后的数据保留了 97.4 的原始信息。基于经济学理论，斯通将这三个新的主成分分别命名为：

1. **总收入** (F_1)：表征经济中的总收入水平。
2. **总收入变化率** (F_2)：表征总收入的变化速度。
3. **经济发展或衰退趋势** (F_3)：表征经济是处于增长还是衰退的趋势。

值得注意的是，这三个变量实际上是可以直接测量的。斯通 进一步对这三个主成分与实际可测量的指标进行了相关性分析，具体包括：

- 实际测量的总收入 (I)
- 总收入变化率 (ΔI)
- 时间因素 (t)

	F_1	F_2	F_3	I	ΔI	t
F_1	1					
F_2	0	1				
F_3	0	0	1			
I	0.995	-0.041	0.057	1		
ΔI	-0.056	0.948	-0.124	-0.102	1	
t	-0.369	-0.282	-0.836	-0.414	-0.112	1

总结：主成分分析旨在寻找一种方法，**用较少的新变量替代较多的旧变量**，同时让新变量尽可能多地保留信息。

有 n 个样本 (row) , 每个样本共有 p 维空间 (column)。


$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

这些变量 (column) 构成一个 $n \times p$ 阶的数据矩阵。

但是这样还是太多了！为了克服这一困难，有必要进行降维处理，即用较少的综合指标替代原始指标，并使这些综合指标尽可能多地反映原始指标所表达的信息，同时，这些综合指标相互独立。


在选择综合指标时，最简单的形式是对原始变量进行**线性组合 Linear Combination**，适当调整组合系数，使新变量相互独立且具有代表性。

为便于理解，我们讨论二维空间中主成分的几何意义。假设有 n 个样本，每个样本有两个观测变量 x_1 和 x_2 。在由变量 x_1 和 x_2 确定的二维平面中， n 个样本点呈椭圆状散布。



可以看出，这 n 个样本点在 x_1 轴或 x_2 轴方向上具有很大的离散度，离散度的大小可以分别用观测变量 x_1 和 x_2 的方差来定量表示。显然，如果只考虑 x_1 或 x_2 中的一个，原始数据所包含的信息将会有显著损失。

如果我们同时平移 x_1 轴和 x_2 轴，并将它们逆时针旋转角度 θ ，就会得到新的坐标轴 z_1 和 z_2 ， z_1 和 z_2 是两个新变量。



$$\begin{cases} z_1 = x_1 \cos \theta + x_2 \sin \theta \\ z_2 = -x_1 \sin \theta + x_2 \cos \theta \end{cases}$$

根据旋转变换公式：

$$\begin{pmatrix} z_1 \\ z_2 \end{pmatrix} = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = U'x$$

其中 U 是一个**正交矩阵 (orthogonal matrix)** 也就是说

$$U' = U^{-1}, U'U = E$$

z_1 、 z_2 不仅能够集中 x_1 、 x_2 所包含的信息，而且还具有不相关的性质，这使得在研究复杂问题时能够避免因信息重叠而导致的虚假性。

二维平面上各点的方差大多归因于 z_1 轴，而 z_2 轴上的方差则非常小。

z_1 和 z_2 被称为原始变量 x_1 和 x_2 的综合变量。 z 简化了系统的结构并抓住了主要矛盾。

旋转变换的目的是使 n 个样本点在 z_1 轴方向上的离散程度达到最大化，也就是说， z_1 的方差最大，并且变量 z_1 代表了原始数据的大部分信息。在研究某些问题时，即便不考虑变量 z_2 ，也几乎不会丢失什么信息。

z_1 被称为**第一主成分**， z_2 被称为**第二主成分**。

总结

设 $x_1, x_2, \dots, x_p$ 为原始变量指标, $z_1, z_2, \dots, z_m$ ($m \leq p$) 为新变量指标, 则

$$\begin{cases} z_1 = l_{11}x_1 + l_{12}x_2 + \dots + l_{1p}x_p \\ z_2 = l_{21}x_1 + l_{22}x_2 + \dots + l_{2p}x_p \\ \vdots \\ z_m = l_{m1}x_1 + l_{m2}x_2 + \dots + l_{mp}x_p \end{cases}$$

$z_1, z_2, \dots, z_m$ 被称为原始变量指标 $x_1, x_2, \dots, x_p$ 的第一、第二、...、第 m 主成分。

z_i 被称为 x_i 的第 i 主成分, x_i 是原始变量指标

因此, 主成分分析的主要任务是确定主成分 z_i ($i = 1, 2, \dots, m$) 中关于系数 l_{ij} 的原始变量 x_j ($j = 1, 2, \dots, p$)。

j 是原始变量 x 的下标, i 是主成分 z 的下标。现在必须确认一个 x 和 z 的系数, 这个系数就是 l_{ij} 。这样就可以关联 z 和 多个 x ...

确定系数 l_{ij} 的原则

- ① z_i 和 z_j ($i \neq j; i, j = 1, 2, \dots, m$) 相互独立;
- ② z_1 是 $x_1, x_2, \dots, x_p$ 所有线性组合中方差最大的, z_2 是 $x_1, x_2, \dots, x_p$ 所有线性组合中方差最大且与 z_1 相互独立的;
- z_m 是 $x_1, x_2, \dots, x_p$ 所有线性组合中方差最大且与 $z_1, z_2, \dots, z_{m-1}$ 相互独立的。

如何计算主成分?

计算相关系数矩阵

原始变量之间的相关性

相关系数矩阵 R 为:

$$R = \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1p} \\ r_{21} & r_{22} & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \dots & r_{pp} \end{bmatrix}$$

其中, $i, j = 1, 2, \dots, p$, r_{ij} 是原始变量 x_i 和 x_j 的相关系数, 且 $r_{ij} = r_{ji}$, 其计算公式为:

$$r_{ij} = \frac{\sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\sqrt{\sum_{k=1}^n (x_{ki} - \bar{x}_i)^2 \sum_{k=1}^n (x_{kj} - \bar{x}_j)^2}}$$

计算特征值和特征向量

- ① 求解特征方程 $|\lambda E - R| = 0$ ，找到特征值，并按大小顺序排列，即 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ 。
- ② 分别找到与特征值 λ_i ($i = 1, 2, \cdots, p$) 对应的特征向量 e_i ，要求 $\|e_i\| = 1$ ，也就是 $\sum_{j=1}^p e_{ij}^2 = 1$ ，其中 e_{ij} 表示向量 e_i 的第 j 个分量。

计算主成分贡献率和累计贡献率

Contribution rate

贡献率: $\frac{\lambda_i}{\sum_{k=1}^p \lambda_k}$ ($i = 1, 2, \cdots, p$)

累计贡献率: $\frac{\sum_{k=1}^i \lambda_k}{\sum_{k=1}^p \lambda_k}$ ($i = 1, 2, \cdots, p$)

一般来说，选取累计贡献率达到80%—90%所对应的第1、第2、.....第 m 个主成分值，即选取 $\lambda_1, \lambda_2, \cdots, \lambda_m$ 。

- 计算主成分载荷
 $p(z_i, x_j) = \sqrt{\lambda_i} e_{ij}$ ($i, j = 1, 2, \cdots, p$)
- 每个主成分的得分：

$$Z = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1m} \\ z_{21} & z_{22} & \cdots & z_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ z_{n1} & z_{n2} & \cdots & z_{nm} \end{bmatrix}$$

计算主成分得分

将标准化数据 $(z_1, z_2, \cdots, z_p)'$ 代入主成分表达式，得到第一主成分的得分，进而得到每个样本单元在各主成分上的得分。

根据主成分得分的大小，可以分析每个样本单元在各主成分上的表现。

综合得分排名

每个主成分代表分析对象在某些方面的表现。所选取的 m 个主成分代表了分析对象的大部分信息，对主成分的综合分析等同于对所有分析对象的综合分析。以 m 个主成分的方差贡献率（特征根）为权重，对 m 个主成分进行加权平均，加权平均公式如下：

$$F = \frac{\alpha_1 Y_1 + \alpha_2 Y_2 + \cdots + \alpha_m Y_m}{\alpha_1 + \alpha_2 + \cdots + \alpha_m}$$

或者

$$F = \frac{\lambda_1 Y_1 + \lambda_2 Y_2 + \cdots + \lambda_m Y_m}{\lambda_1 + \lambda_2 + \cdots + \lambda_m}$$

得到主成分的综合得分 F ，该得分保留了大部分信息，其数值大小能够反映分析对象的综合表现。根据主成分得分的高低来评判每个对象的表现情况，从而达到排名的目的。

示例

有三个指标 X_1 、 X_2 、 X_3 ，得到样本相关系数矩阵 (coefficient matrix) R 为：

$$R = \begin{pmatrix} 1 & 0.632 & -0.867 \\ 0.632 & 1 & -0.331 \\ -0.867 & -0.331 & 1 \end{pmatrix}$$

对应的特征方程为

$$\begin{vmatrix} \lambda - 1 & -0.632 & 0.867 \\ -0.632 & \lambda - 1 & 0.331 \\ 0.867 & 0.331 & \lambda - 1 \end{vmatrix} = 0$$

展开行列式 (determinant) 并计算后得到关于 λ 的特征方程：

$$\lambda^3 - 3\lambda^2 + 1.74\lambda - 0.103 = 0$$

并且可以得到三个特征根：

$$\lambda_1 = 2.245, \lambda_2 = 0.688, \lambda_3 = 0.067$$

第一个特征值 $\lambda_1 = 2.245$ 对应的特征向量 α_1 应满足方程 $(2.245E - R)\alpha_1 = 0$ $\alpha_1 = \begin{pmatrix} \alpha_{11} \\ \alpha_{21} \\ \alpha_{31} \end{pmatrix}$ 且

$$\alpha_{11}^2 + \alpha_{21}^2 + \alpha_{31}^2 = 1$$

因此

$$\begin{pmatrix} 2.245 - 1 & -0.632 & 0.867 \\ -0.632 & 2.245 - 1 & 0.331 \\ 0.867 & 0.331 & 2.245 - 1 \end{pmatrix} \begin{pmatrix} \alpha_{11} \\ \alpha_{21} \\ \alpha_{31} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

也就是说

$$\begin{cases} 1.245\alpha_{11} - 0.632\alpha_{21} + 0.867\alpha_{31} = 0 \\ -0.632\alpha_{11} + 1.245\alpha_{21} + 0.331\alpha_{31} = 0 \\ 0.867\alpha_{11} + 0.331\alpha_{21} + 1.245\alpha_{31} = 0 \end{cases}$$

得到：

$$\alpha_{11} = 0.6520, \alpha_{21} = 0.4857, \alpha_{31} = 0.5822$$

那么，第一主成分是 $F_1 = 0.652X_1 + 0.4857X_2 + 0.5822X_3$ 通过同样的方法，分别针对 λ_2 、 λ_3 可以得到对应的特征向量 $(\alpha_{12}, \alpha_{22}, \alpha_{32})$ 和 $(\alpha_{13}, \alpha_{23}, \alpha_{33})$ 。

由此，得到第二主成分 F_2 和第三主成分 F_3 。

因此

- 在创建第一个主成分时，主成分分析 (PCA) 得出预测变量的线性组合，该组合能最大化总方差解释率。
- 这个线性组合随后成为第一个“新”的预测变量 Z_1 。
- 主成分分析重复此过程，使用相同的变量但赋予不同的权重，以创建第二个新的预测变量 Z_2 。权重的设定要使得 Z_1 和 Z_2 不相关。

- 这个过程持续进行，直到得到与原始变量 X_i 数量相同的新变量或成分 Z_i 。
- 选择保留足够数量的成分，以解释大部分方差。
- 到目前为止，结果是每个成分的一组权重。最后一步是通过将这些权重应用于原始值，将原始数据转换为新的主成分得分。这些新得分随后可以用作精简后的预测变量集。

为什么在机器学习中需要主成分分析 PCA?

处理高维数据会导致**过拟合问题**，我们将使用降维的方法来解决这些问题。

PCA能够增强可解释性并最小化信息损失，有助于定位重要特征，还有助于发现不同序列的线性组合。

在机器学习中何时应该使用主成分分析?

- 当我们需要了解特征之间是否相互独立时；
- 当我们需要从大量特征中提取较少的特征时。

机器学习中主成分分析 PCA 的Python代码


完整代码

```
1  #导入了numpy用于数值计算
2  import numpy as np
3  # matplotlib.pyplot用于数据可视化
4  import matplotlib.pyplot as plt
5
6  # 设置随机数种子，保证结果可复现
7  rng = np.random.RandomState(1)
8  # 生成一个二维的数据集X，它是两个随机矩阵的乘积转置，包含 200 个样本，每个样本有 2 个特征。
9  X = np.dot(rng.rand(2, 2), rng.randn(2, 200)).T
10 # 绘制原始数据的散点图
11 plt.scatter(X[:, 0], X[:, 1])
12 # 确保横纵坐标轴的刻度比例一致
13 plt.axis('equal')
14
15 # PCA 分析
16 from sklearn.decomposition import PCA
17 # 创建一个 PCA 对象，指定保留 2 个主成分
18 pca = PCA(n_components=2)
19 # 对原始数据X进行拟合，计算主成分相关参数
20 pca.fit(X)
21 # 打印主成分向量
22 print(pca.components_)
23 # 打印每个主成分所解释的方差
24 print(pca.explained_variance_)
25
26 # 函数用于绘制向量
27
28 def draw_vector(v0, v1, ax=None):
29     ax = ax or plt.gca()
30     # noinspection SpellCheckingInspection
```

```

31     arrowprops=dict(arrowstyle='->',
32                     linewidth=2,
33                     shrinkA=0, shrinkB=0)
34     ax.annotate("", v1, v0, arrowprops=arrowprops)
35
36 # 重新绘制原始数据散点图，并根据主成分解释的方差和主成分向量绘制主成分向量，展示数据的主要变化方向
37 # plot data
38 plt.scatter(X[:, 0], X[:, 1], alpha=0.2)
39 for length, vector in zip(pca.explained_variance_, pca.components_):
40     v = vector * 3 * np.sqrt(length)
41     draw_vector(pca.mean_, pca.mean_ + v)
42 plt.axis('equal')
43
44 # 创建一个只保留 1 个主成分的 PCA 对象并拟合数据
45 pca = PCA(n_components=1)
46 # 拟合
47 pca.fit(X)
48 # 将原始数据X转换到主成分空间，实现降维
49 X_pca = pca.transform(X)
50 # 打印原始数据和降维后数据的形状
51 print("original shape: ", X.shape)
52 print("transformed shape:", X_pca.shape)
53
54 # 进行逆变换，将降维后的数据转换回原始特征空间
55 X_new = pca.inverse_transform(X_pca)
56 # 分别绘制原始数据和逆变换后数据的散点图，对比展示降维与逆变换的效果
57 plt.scatter(X[:, 0], X[:, 1], alpha=0.2)
58 plt.scatter(X_new[:, 0], X_new[:, 1], alpha=0.8)
59 plt.axis('equal')
60
61 plt.show()


```



■ [Week 5]

[Gaussian Mixture Models or GMM](#) 和 [DBScan](#) 在这节课被提及

机器学习模式



KNN	K近邻算法
Logistic Regression	逻辑回归
SVM	支持向量机
CART	分类与回归树
Linear Regression	线性回归
Ridge Regression	岭回归
Lasso	套索回归
K-means	K均值算法
Hierarchical	层次聚类算法
PCA	主成分分析

无监督学习

一组用于处理仅包含特征/输入但没有响应变量的数据的统计工具。


换句话说，我们有特征数据 X ，但没有标签 y 。

目标：发现数据中有趣的模式或特性。例如，用于可视化或解读高维数据。

示例

给定 n 位乳腺癌患者的组织样本，识别出乳腺癌的未知亚型。

基因表达实验会产生数千个变量。使用更少的一组特征来呈现数据，以便进行可视化和分析。



两种方法

1. 聚类分析

- 用于识别样本中的同质子组。

2. 降维

- 用于找到一种低维表示，以便描述数据特征和进行数据可视化。 PCA!

高斯混合模型（GMM）的标准构建

K个高斯分布的线性叠加

- μ_k : 均值 Mean
- σ_k : 协方差 Covariance
- 概率公式为: $p(\mathbf{x}_i) = \sum_{k=1}^K \underbrace{\pi_k}_{p(k)} \underbrace{\mathcal{N}(\mathbf{x}_i | \mu_k, \sigma_k)}_{p(\mathbf{x}_i | k)}, i = 1, \dots, N$
- 这个被称为高斯混合（GM）。混合系数 π_k 满足: $\sum_{k=1}^K \pi_k = 1, \quad 0 \leq \pi_k \leq 1$

解释: 密度函数 $p(\mathbf{x} | k) = \mathcal{N}(\mathbf{x} | \mu_k, \sigma_k)$ 是在选择了第 k 个分量的情况下, $\mathbf{x}$ 的概率。选择第 k 个分量的概率由先验概率 $p(k)$ 给出。

例如, 考虑以下高斯混合模型:

$$p(x) = \underbrace{0.3}_{\pi_1} \mathcal{N}\left(x \middle| \begin{pmatrix} 4 \\ 4.5 \end{pmatrix}, \begin{pmatrix} 1.2 & 0.6 \\ 0.6 & 0.5 \end{pmatrix}\right) + \underbrace{0.5}_{\pi_2} \mathcal{N}\left(x \middle| \begin{pmatrix} 8 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}\right) + \underbrace{0.2}_{\pi_3} \mathcal{N}\left(x \middle| \begin{pmatrix} 9 \\ 8 \end{pmatrix}, \begin{pmatrix} 0.6 & 0.5 \\ 0.5 & 1.5 \end{pmatrix}\right)$$




Figure: Probability density function.

概率密度函数




Figure: Contour plot.

等高线模型

高斯混合 (GM) 分布的形式由参数 π , μ 和 σ 决定。获取这些参数的一种方法是通过最大似然法。

给定 N 个观测值 $\{x_n\}_{n=1}^N$, 对数似然函数为

$$\ln p(X; \pi_{1:K}, \mu_{1:K}, \sigma_{1:K}) = \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \sigma_k) \right)$$

由于对数函数内部存在求和, 所以不存在封闭形式的解。

这个问题可以使用期望最大化 (EM) 算法分解为两个简单的问题。

似然函数(Likelihood function)达到最大值时需满足的条件

对 $\ln p(x|\pi, \mu, \sigma)$ 关于 μ_k 求导:

$$\frac{d}{d\mu_k} [\ln p(x|\pi, \mu, \sigma)] = 0 \Rightarrow 0 = - \sum_{n=1}^N \underbrace{\frac{\pi_k \mathcal{N}(x_n | \mu_k, \sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n | \mu_j, \sigma_j)}}_{\gamma(z_{nk})} \sigma_k (x_n - \mu_k)$$

由此可得: $\Rightarrow \mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_n$

对 $\ln p(x|\pi, \mu, \sigma)$ 关于 σ_k 求导:

$$\frac{d}{d\sigma_k} [\ln p(x|\pi, \mu, \sigma)] = 0 \Rightarrow \sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k)(x_n - \mu_k)^T$$

使用拉格朗日乘数法, 对 $\ln p(x|\pi, \mu, \sigma)$ 关于 π_k 求最大值, 可得:

$$\pi_k = \frac{N_k}{N}, \text{ 其中 } N_k = \sum_{n=1}^N \gamma(z_{nk})$$

算法1 用于高斯混合模型的期望最大化 (EM) 算法

Algorithm 1 EM for Gaussian mixtures

- 1: Initialize $\mu_k^1, \sigma_k^1, \pi_k^1$ and set $i = 1$.
- 2: **while** not converged **do**
- 3: Compute $\gamma(z_{nk})$. ▷ Expectation step
- 4: Compute $\mu_k^{i+1}; \pi_k^{i+1}; N_k; \sigma_k^{i+1}$. ▷ Maximization step
- 5: $i \leftarrow i + 1$.
- 6: **end while**

$$\gamma(z_{nk}) = \frac{\pi_k^i \mathcal{N}(x_n | \mu_k^i, \sigma_k^i)}{\sum_{j=1}^K \pi_j^i \mathcal{N}(x_n | \mu_j^i, \sigma_j^i)}, n = 1, \dots, N; k = 1, \dots, K$$

$$\mu_k^{i+1} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_n,$$

$$\pi_k^{i+1} = \frac{N_k}{N}, \quad N_k = \sum_{n=1}^N \gamma(z_{nk}),$$

$$\sigma_k^{i+1} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k^{i+1}) (x_n - \mu_k^{i+1})^T.$$


用Python实现 GMM

到目前为止，我们已经讨论了高斯混合模型的工作原理。下面我们以鸢尾花（Iris）数据集为例进行一个简单的演示，拟合一个具有3个簇的高斯混合模型（因为我们知道鸢尾花有3个品种）。

1. **数据集**：我们仅使用两个特征，即花萼长度和花萼宽度。
2. **拟合模型**：将数据拟合为3个高斯分布的混合。
3. **结果**：模型根据概率将每个数据点分配到一个簇中。收敛后，高斯混合模型将更新参数，以最佳地拟合数据。

数据库可以在 [Iris - UCI Machine Learning Repository](https://archive.ics.uci.edu/ml/datasets/Iris) 找到

```
1 from sklearn.mixture import GaussianMixture
2 import matplotlib.pyplot as plt
3 from sklearn.datasets import load_iris
4
5 iris = load_iris()
6 x = iris.data[:, :2]
7 print(iris.data) # [x, y] x ↓ y →
8
9 gmm = GaussianMixture(n_components=3, covariance_type='full')
10 gmm.fit(x)
11
12 labels = gmm.predict(x)
13
14 plt.scatter(x[:, 0], x[:, 1], c=labels, cmap='viridis')
15 plt.xlabel('Sepal Length')
16 plt.ylabel('Sepal width')
17 plt.title('Gaussian Mixture Model Clustering')
```



这张散点图展示了使用高斯混合模型（GMM）对数据进行聚类的结果。数据点代表了基于花萼长度和花萼宽度对花卉品种的测量值。这些点被分为三个簇，分别用不同的颜色（黄色、紫色和绿色）表示，这表明高斯混合模型在数据中识别出了三个不同的组别。

GMM 优点

1. **灵活的簇形状**：与假设簇为球形的K均值算法不同，高斯混合模型可以对任意形状的簇进行建模。
2. **软分配**：高斯混合模型为每个数据点分配属于每个簇的概率，而K均值算法将每个点确切地分配到一个簇中。
3. **处理重叠数据**：当簇之间存在重叠或密度不同时，高斯混合模型表现良好。由于它使用概率分布，因此可以将一个点以不同的概率分配到多个簇中。

GMM 局限性

1. **计算复杂度**：高斯混合模型的计算成本往往较高，尤其是对于大型数据集，因为它需要诸如期望最大化（EM）算法这样的迭代过程来估计参数。
2. **选择簇的数量**：与其他聚类方法一样，高斯混合模型需要事先指定簇的数量。不过，像贝叶斯信息准则（BIC）和赤池信息准则（AIC）这样的方法可以帮助根据数据选择最优的簇数。

聚类分析之 DBScan

一组用于在数据集中寻找子组的方法...**聚类分析**！

- 同一组内的观测值应具有**共同的特征**，而不同组之间的观测值则存在差异。
- **分组**是由数据本身的属性决定的，这与**分类**有所不同。



[图]左侧：原始数据 右侧：聚类数据

基于质心的聚类 (Centroid-based Clustering)


层次聚类 (Hierarchical Clustering)

基于模型的聚类 (Model-based clustering)



- 每个簇 (Cluster) 由一个**参数化分布**表示
- 数据集是多种分布的混合

硬聚类、软聚类、模糊聚类 (Hard, Soft, Fuzzy Clustering)

- 硬聚类：观测值被划分到不同的明确簇中
- 软聚类：观测值可能属于多个簇



其中，DBScan全称 **Density-Based Spatial Clustering**，就是**基于密度的空间聚类**...



用 Python 实现 DBScan

[DBScan Clustering IRIS \(kaggle.com\)](https://www.kaggle.com/competitions/dbscan-clustering-iris)

Figure 1

```
1 import numpy as np
2 import pandas as pd
3
4 from sklearn import datasets
5 from sklearn.cluster import DBSCAN
6
7 import matplotlib.pyplot as plt
8 import seaborn as sns
```

```

9
10 iris = datasets.load_iris()
11
12 data_y = pd.DataFrame(iris.target)
13 data_y.columns = ['original_label']
14
15 data_x = pd.DataFrame(iris.data)
16 data_x.columns = ['Sepal length', 'Sepal width', 'Petal length', 'Petal width']
17
18 train = pd.concat([data_x, data_y], axis = 1)
19 train.head()
20
21 sns.color_palette("pastel")
22 sns.pairplot(train, hue='original_label')
23 plt.show()

```

Figure 2

```

1 TRAIN_LABEL_COL = 'original_label'
2 TRAIN_FEATURE = [col for col in train.columns if col != TRAIN_LABEL_COL]
3 X = train[TRAIN_FEATURE]
4 y = train[TRAIN_LABEL_COL]
5
6 dbscan = DBSCAN(eps=0.5, min_samples=5)
7 y_pred = dbscan.fit_predict(X)
8
9 y_pred_df = pd.DataFrame(y_pred)
10 y_pred_df.columns = ['pred_label']
11 val = pd.concat([X, y_pred_df], axis=1)
12
13 sns.color_palette("pastel")
14 sns.pairplot(val, hue='pred_label')
15 plt.show()
16
17 print(val)

```




FIGURE 1




FIGURE 2

